Faculté des sciences exactes
Département Maths et Informatique

Théorie des langages (Formal Language Theory)

Les phrases d’un langage et la grammaire

L’étudiant prépare ses examens

- Vocabulaire=Alphabet={l’, étudiant, prépare, ses, examens}
- Les catégories syntaxique:
  - ✓ Phrase (PH)
  - ✓ groupe nominal (GN)
  - ✓ Verbe (V)
  - ✓ Déterminant (D)
  - ✓ Nom (N)

L’étudiant prépare ses examens

- Les règles de construction de ces catégories:

PH → GN V GN

GN → D N

V → **prépare**

D → **L’** ou bien **ses**

N → **étudiant** ou bien **examens**

Les phrases d’un langage et la grammaire

L’étudiant prépare ses examens

- La phrase suit la grammaire envisagée:

PH => GN V GN => D N V GN => l’ N V GN

=> L’étudiant V GN => L’étudiant prépare GN

=> L’étudiant prépare ses N => L’étudiant prépare ses examens

Les phrases d'un langage et la grammaire

- La fonction de la Grammaire est de:

  1. Indiquer comment construire des phrases appartenant à un langage (**Production**)

  2. Décider si une phrase donné appartient ou non à un langage (**reconnaissance**)

Notations de base

- Différentes classes de langages ⇒ Différentes classes de grammaires
- Différentes classes de grammaires ⇒ Différentes classes d'automates
- Langages de programmation décrits pare grammaire régulière et utilise les automates à états finis.

Grammaire

Grammaire: Définition

Une grammaire est un quadruplet (T, N, R, S) tel que:

- **T**: est l'ensemble des terminaux c-à-d le vocabulaire terminal ou l'alphabet du langage.
- **N**: est le vocabulaire non terminal, c-à-d l'ensemble des symboles n'apparaissent pas dans les mots générés, mais qui sont utilisés au cours de la génération.
- **R**: est un ensemble de règles dites de réécriture ou de production de la forme:

$$u_1 \longrightarrow u_2, avec\ u_1 \in (N \cup T)^+\ et\ (N \cup T)^*$$

- **S**: le symbole de départ ou **axiome**.

Grammaire: Définition

$$u_1 \longrightarrow u_2, avec\ u_1 \in (N \cup T)^+\ et\ u_2 \in (N \cup T)^*$$

- Ces règles signifient que la suite non vide des terminaux ou non terminaux u_1 peut être remplacée par la suite éventuellement vide de symboles terminaux ou non terminaux u_2.

- Un élément de $(N \cup T)^*$ est appelé une **forme**

- Une règle $u_1 \longrightarrow u$ telle que $u \in T^*$ est appelé une règle terminale

Dérivation et langage engendré

Grammaire: dérivation et langage engendré

- Un langage engendré ou généré par une grammaire est l'ensemble des mots qui peuvent être obtenus à partir du symbole de départ par l'application des règles de la grammaire.

- On a 2 types de dérivation: dérivation en une étape et dérivation en plusieurs étapes.

Dérivation en une étape

Soit une grammaire G=(T,N,S,R), une forme non vide $u \in (N \cup T)^+$ et une forme éventuellement vide $v \in (N \cup T)^*$. La grammaire G permet de dériver v de u en une étape (noté $u \Rightarrow v$) ssi:

- ✓ $u = xu'y$ (u peut être décomposé en x, u' et y; x et y peuvent être vides),
- ✓ $v = xv'y$ (v peut être décomposé en x, v' et y),
- ✓ $u' \longrightarrow v'$ est une règle de R.

Exemple:

Soit G=($\{S\}$, $\{a, b\}$, $\left\{S \to aSb, S \to \varepsilon\right\}$,S)

On peut dire que:

S dérive directement aSb et on note: S⇒ aSb car

$$\begin{cases} \exists \quad S \to aSb \in R \\ telle\ que\ w = S\ et\ w' = aSb \\ avec\ u = v = \varepsilon \in (N \cup T)^* \end{cases}$$

aSb dérive directement ab et on note: aSb ⇒ab car

$$\begin{cases} \exists \quad S \to \varepsilon \in R \\ telle\ que\ w = aSb\ et\ w' = ab \\ avec\ u = a\ et\ v = b \in (N \cup T)^* \end{cases}$$

Dérivation en plusieurs étapes

Une forme v peut être dérivé d'une forme u en plusieurs étapes en passant un certain nombre de fois par les règles de production , et on note:

$$u \overset{*}{\Rightarrow} v$$

Exemple

- Soit la grammaire $G = (\{0,1\}, \{S, T, O, I\}, S, P\}$ tel que P:
- $S \rightarrow OT, T \rightarrow SI, S \rightarrow OI, I \rightarrow 1\ et\ O \rightarrow 0$
- 0011 ??
- $S \Rightarrow OT \Rightarrow 0T \Rightarrow 0SI \Rightarrow 0OII \Rightarrow 00II \Rightarrow 001I \Rightarrow \mathbf{0011}$

Langage engendré ou généré

Le langage généré par une grammaire G=(T,N,S,R) est l'ensemble des mots sur T qui peuvent être dérivés à partir de S:

$$L(G) = \{v \in T^* : S \overset{+}{\Rightarrow} v\}$$

Grammaire et langage engendré

Remarque:

- Une grammaire définit un **seule** langage mais un même langage peut être engendré par **plusieurs** grammaires différentes.

Exemple

- la grammaire $G = (\{S\}, \{a, b\}, S, R)$ tel que $R: S \to aSb, S \to \varepsilon$

- Le mot minimal est: $S \Rightarrow \varepsilon$

- $S \Rightarrow aSb \Rightarrow$aaSbb$\Rightarrow$aaaSbbb$\Rightarrow$.....$\Rightarrow a^n S b^n \Rightarrow a^n b^n$
- Donc le langage engendrer par cette grammaire est

$$L(G) = \{a^n b^n : n \geq 0\}$$

Types des grammaires & Hiérarchie de Chomsky

Types des grammaires selon Chomsky

- En 1956, **Noam Chomsky** a proposé une classification des grammaires selon leur complexité en se basant sur la forme des règles.

- Chomsky a ainsi proposé quatre classes (hiérarchiques) de grammaires (et de langages), de sorte qu'une grammaire de type i génère un langage de type j, avec $j \geq i$.

Grammaires Régulières (grammaire de type 3)

- On dit qu'une grammaire est de type 3 **ssi** elle est régulière à droite ou régulière à gauche.

- Une grammaire est régulière à droite si ses règle sont de la forme $A \rightarrow \omega B$ ou $A \rightarrow \omega$ avec $A, B \in N$ et $\omega \in T^*$.

- Une grammaire est régulière à gauche si ses règle sont de la forme $A \rightarrow B\omega$ ou $A \rightarrow \omega$ avec $A, B \in N$ et $\omega \in T^*$.

Langage Régulier

- ✓ Un langage est régulier s'il peut être engendré par une grammaire régulière.

- ✓ Ce type des langages peuvent être reconnus par des automates à états finis (AEF).

Exemple

- la grammaire régulière $G = (\{a, b, c\}, \{S, A\}, S, P\}$ tel que P:
- $S \rightarrow aS, S \rightarrow bA, A \rightarrow \epsilon \; et \; A \rightarrow cA$
- Défini le langage régulier $L(G) = \{u : u = a^n bc^m \; avec \; , m \in \mathbb{N}\}$

Grammaires hors-contexte ou libre (type 2)

- On dit qu'une grammaire est de type 2 ou hors-contexte **ssi** tous ses règles sont de la forme:

✓ $A \rightarrow B$ avec $A \in N$ et $B \in (T \cup N)^*$.

Grammaires hors-contexte ou libre (type 2)

- ✓ Un langage est hors-contexte ou algébrique s'il peut être engendré par une grammaire hors-contexte.

- ✓ Ce type des langages peuvent être reconnus par des automates à pile (AàP).

Exemple

- La grammaire hors-contexte $G = (\{0,1\}, \{S, T, O, I\}, S, P\}$ tel que P:
- $S \rightarrow OT, T \rightarrow SI, S \rightarrow OI, I \rightarrow 1 \; et \; O \rightarrow 0$
- Défini le langage algébrique $L(G) = \{0^n 1^n : n \geq 1\}$

Grammaires monotone (type 1)

- On dit qu'une grammaire est monotone (ou de type 1), **ssi** tous ses règles sont de la forme:

$$A \rightarrow B \text{ avec } |A| \leq |B|.$$

et

$$A \in (T \cup N)^{+} - T^{+} \text{ et } B \in (T \cup N)^{*}$$

Exception: l'axiome $\rightarrow \varepsilon$ peut appartenir à P

Exemple

La grammaire monotone $G = (\{a, b, c\}, \{S, Q\}, S, P\}$ tel que P:

$S \rightarrow aSQ, S \rightarrow abc, cQ \rightarrow Qc$ et $bQc \rightarrow bbcc$

Défini le langage sensible au contexte $L(G) = \{a^n b^n c^n, n \geq 1\}$

Grammaires de type 0

- On appelle grammaire de type 0 une grammaire **sans restriction** dans laquelle la forme des productions est sans contrainte

✓ $A \rightarrow B$ avec :

- $A \in (T \cup N)^+ - T^+$ et $B \in (T \cup N)^*$

Langages semi-décidables ou récursivement énumérables

- ✓ Un langage est semi-décidable ou récursivement énumérable s'il peut être engendré par une grammaire de type 0.
- ✓ Cet ensemble de langages peut être reconnu par les machines de Turing (MT).

Hiérarchie de Chomsky

Hiérarchie de Chomsky

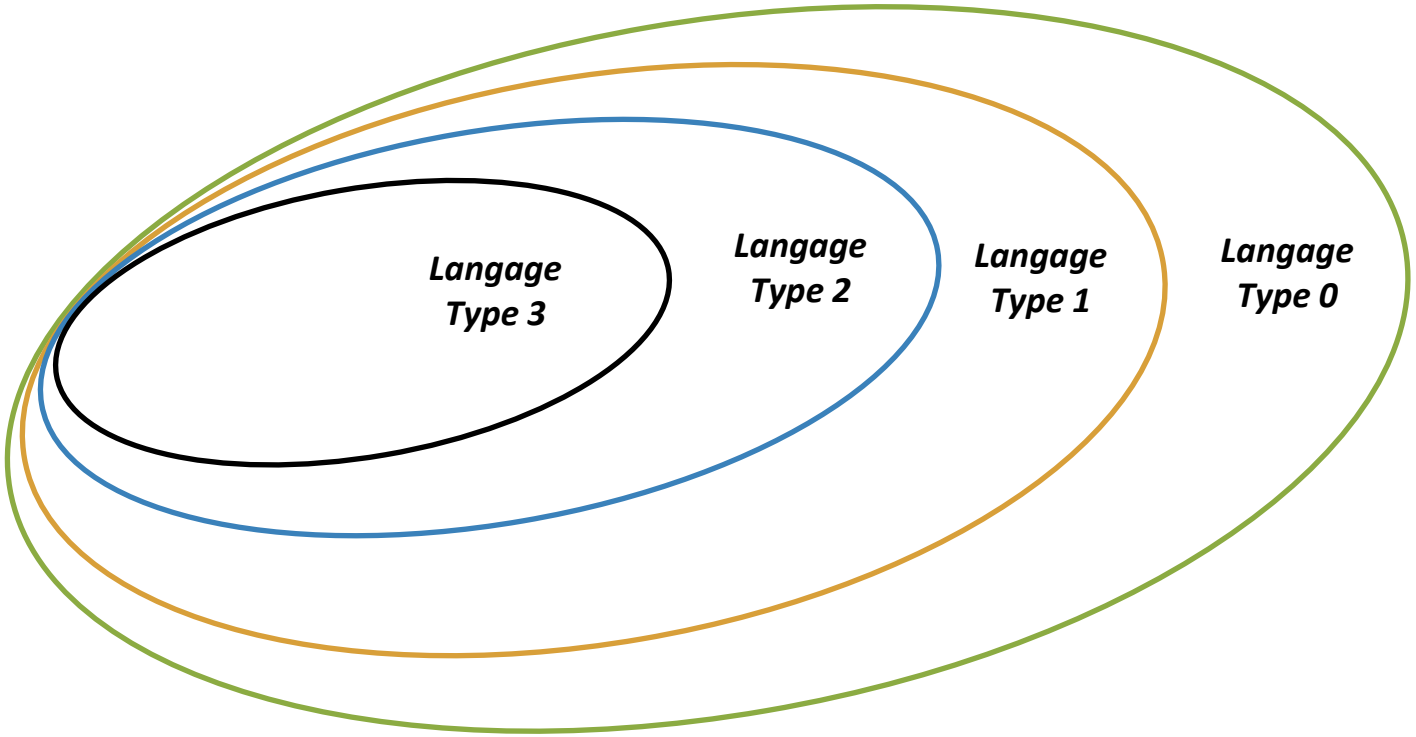

Arbre de dérivation

Arbre syntaxique

- Vue l'utilisation d'un seul symbole non terminal à gauche des règles de production dans les grammaires à contexte libre, il est toujours possible de construire un arbre de dérivation pour un mot généré tel que:

  - ✓ La racine de l'arbre est étiquetée par l'axiome ;
  - ✓ Les nœuds intermédiaires contiennent des non terminaux ;
  - ✓ Les feuilles sont des terminaux.

Exemple

- la grammaire $G = (\{0,1\}, \{S, T, O, I\}, S, P\}$ tel que P:
- $S \rightarrow OT, T \rightarrow SI, S \rightarrow OI, I \rightarrow 1 \; et \; O \rightarrow 0$
- L'arbre du mot 0011?
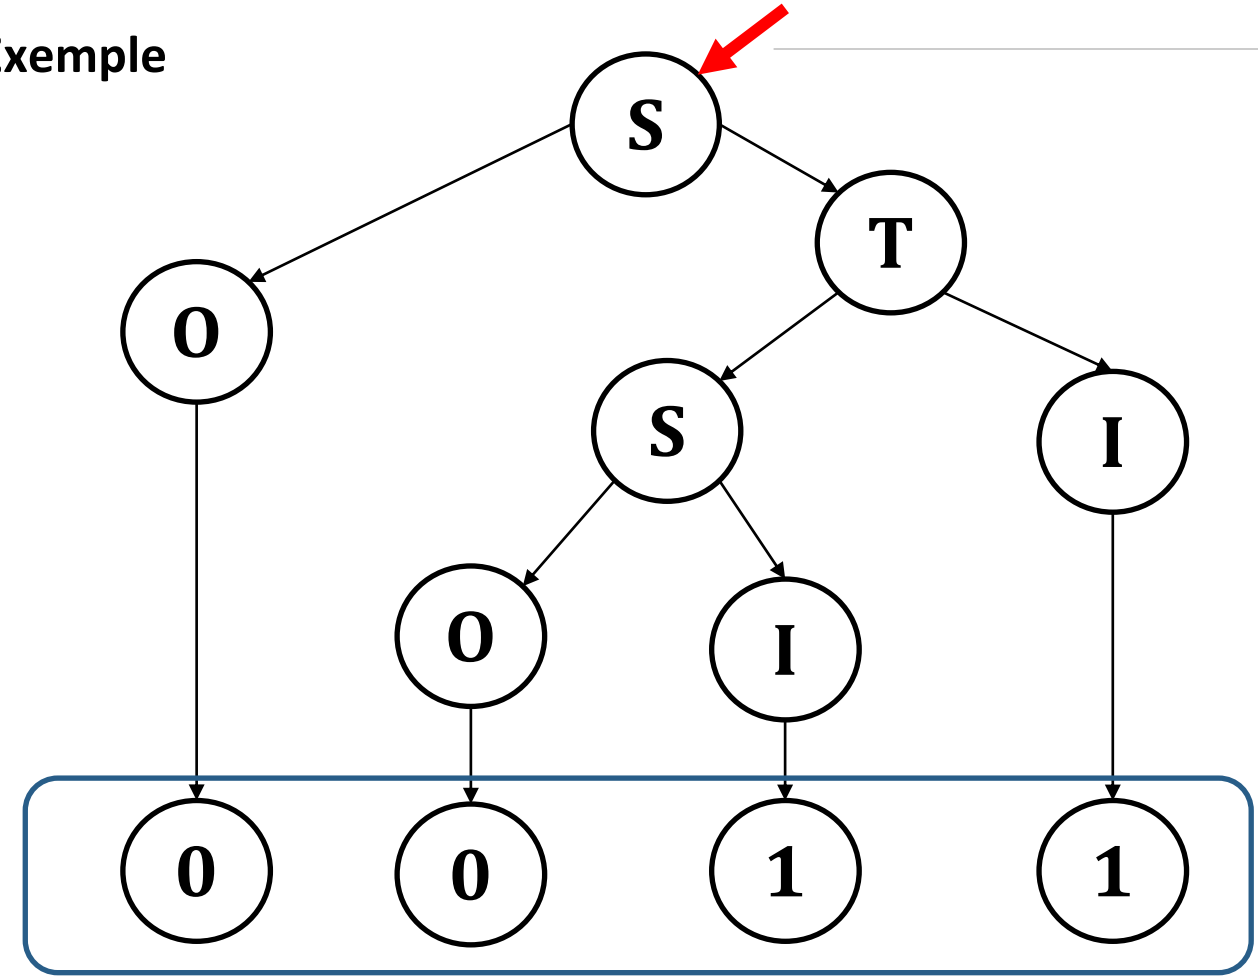
Exemple